Arquitectura del Pipeline

> Documentación técnica del pipeline Spotify Analytics. Creada para el proyecto final BSG.

Cómo funciona el pipeline (overview)

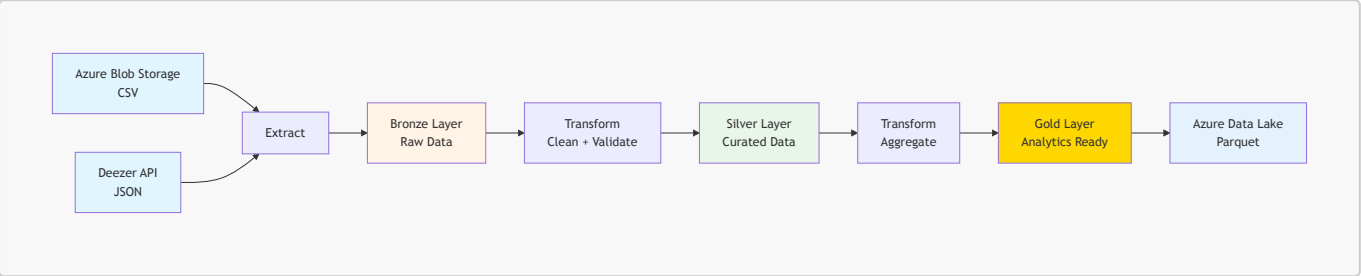

Arquitectura Medallion (Bronze/Silver/Gold)

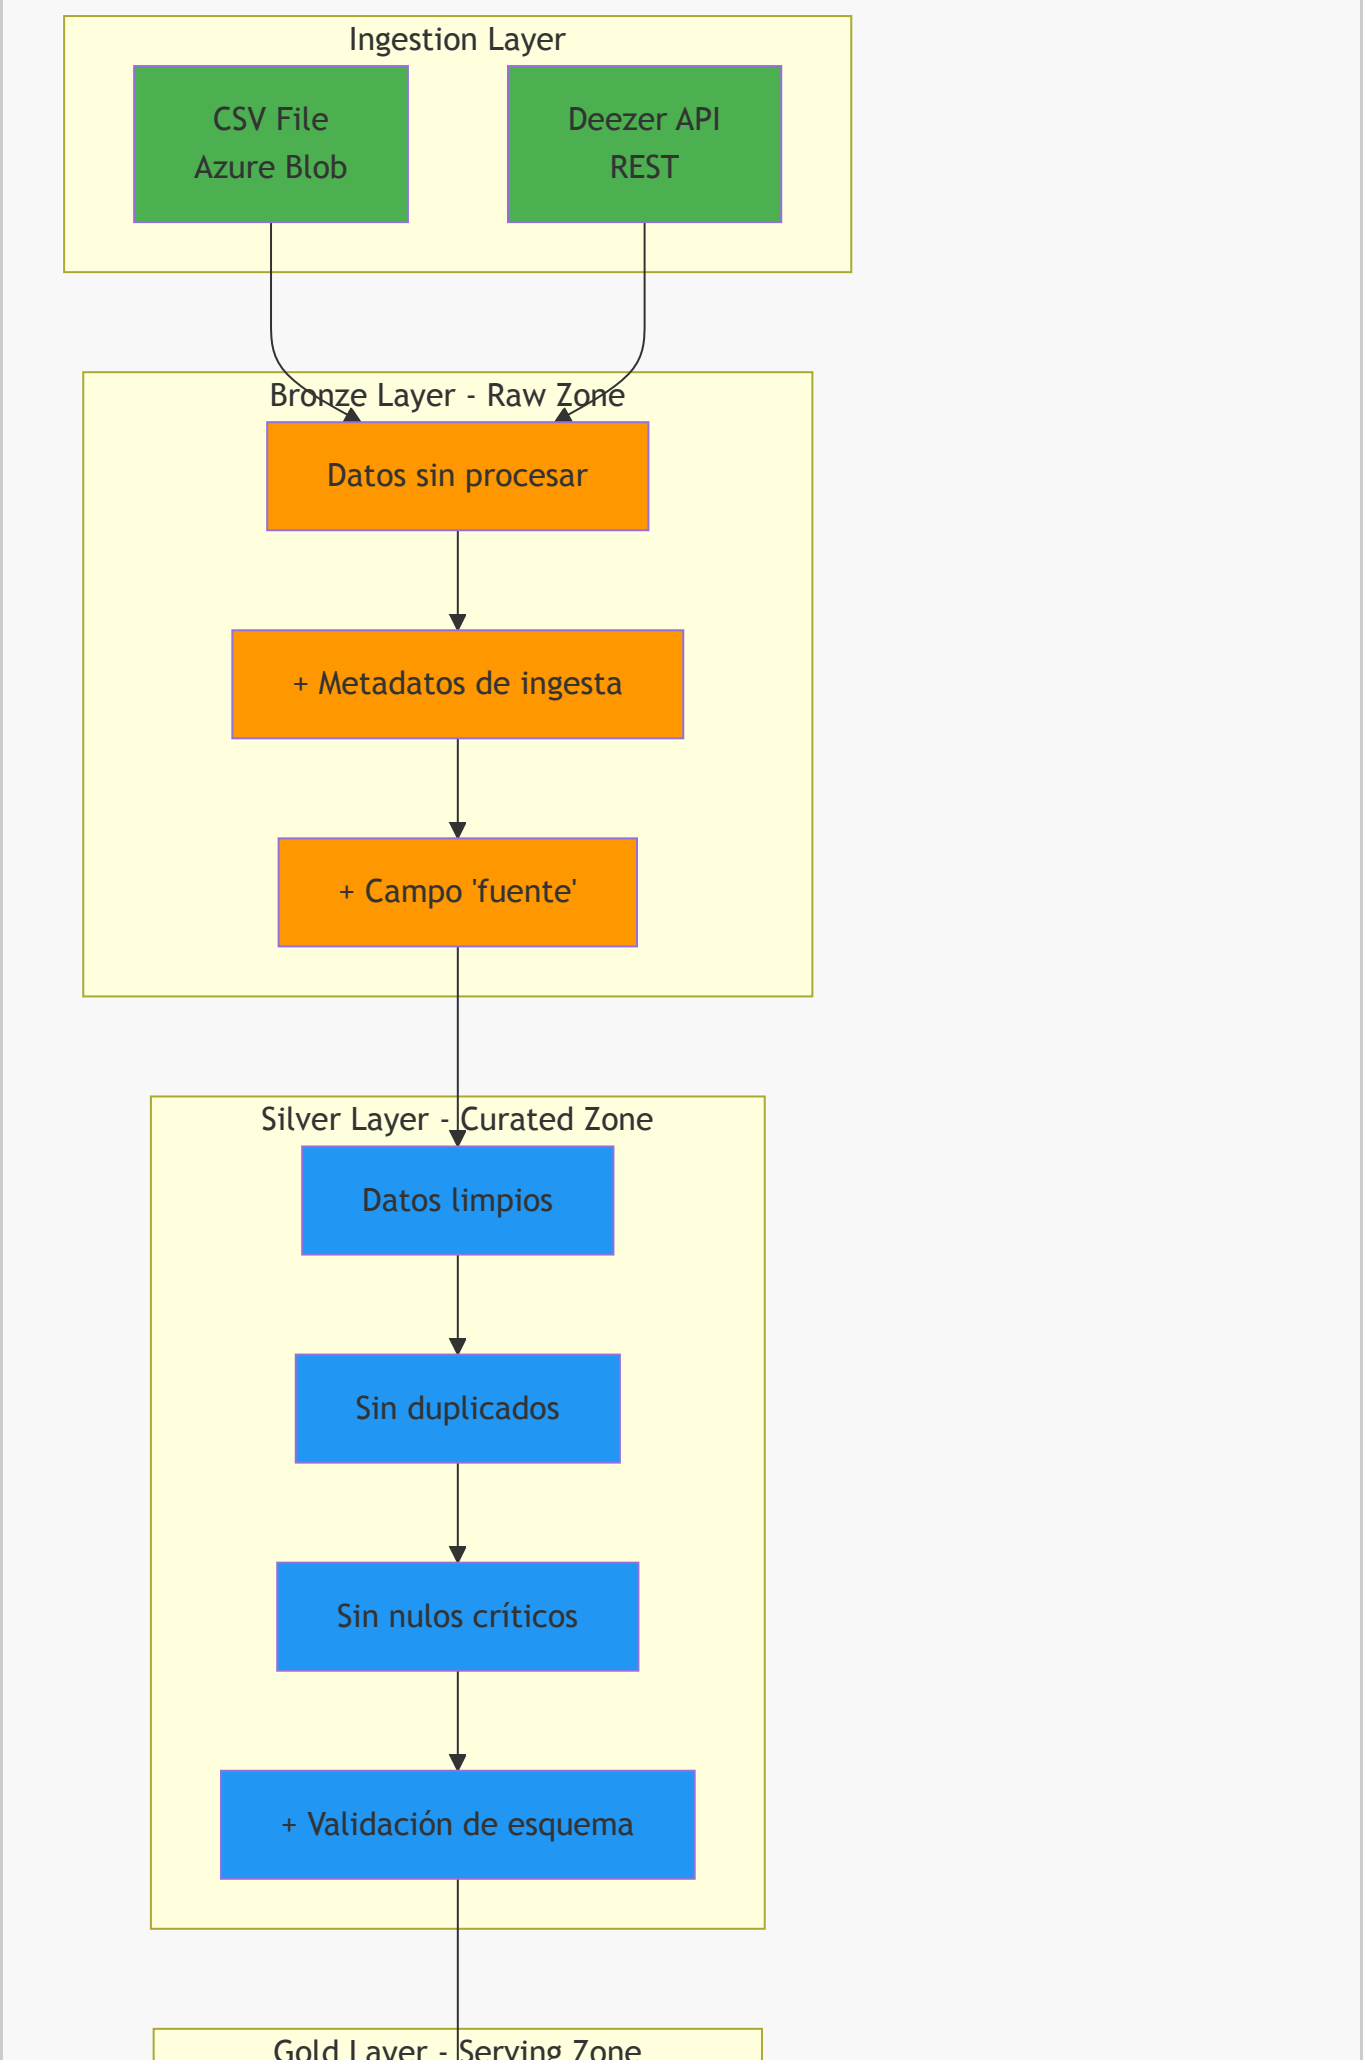
Ingestion Layer
CSV File
Azure Blob
Deezer API
REST
Bronze Layer - Raw Zone
Datos sin procesar
+ Metadatos de ingesta
+ Campo 'fuente'
Silver Layer - Curated Zone
Datos limpios
Sin duplicados
Sin nulos críticos
+ Validación de esquema
Gold Layer - Serving Zone

La idea es simple: Bronze = datos crudos, Silver = limpio, Gold = listo para análisis.

Servicios de Azure que uso

| Servicio | Para qué lo uso | | Azure Blob Storage | Guardar el CSV de entrada | | Deezer API | API pública de música (más simple que Spotify) | | Azure Data Lake Gen2 | Almacenar Bronze/Silver/Gold en Parquet | | (Futuro) Azure Data Factory | Automatizar ejecuciones | | (Futuro) Synapse Analytics | Hacer queries SQL sobre los datos |

Flujo del pipeline

Paso 1: Extracción

```
# 1. Bajar CSV de Azure Blob
df_csv = dwspotify()

# 2. Llamar a Deezer API para más datos
df_api = llamar_api()
```

Nota: Si la API falla, el pipeline sigue solo con CSV.

Paso 2: Capa Bronze

2. Llamar a Deezer API

df_api = llamar_api()

Retorna: DataFrame con top tracks de 10 artistas

```
**Características:**
- Timeout de 10 segundos por request
- Manejo de errores por artista (continúa si uno falla)
- Sin autenticación (API pública)

### 3.2 Fase de Transformación Bronze

```python
datos_bronze = crear_bronze(df_csv, df_api)
```
```

Operaciones:

1. Agregar columna `fuente` ('CSV' o 'API')
2. Combinar ambos DataFrames con `concat()`
3. Agregar timestamp de ingesta
4. Validar esquema contra `bronze_schema.json`

Particionado: `bronze/spotify/ingestion_date=YYYY-MM-DD/`

3.3 Fase de Transformación Silver

```
datos_silver = limpiar_datos(datos_bronze)
```

Operaciones:

1. Eliminar filas con `nombre_artista` nulo
2. Eliminar duplicados por `(id_artista, cancion)`
3. Agregar `fecha_procesamiento`
4. Validar esquema contra `silver_schema.json`

Particionado: `silver/spotify/event_date=YYYY-MM-DD/`

3.4 Fase de Transformación Gold

```
datos_gold = agregar_metricas(datos_silver)
```

Agrupa por artista y calcula:

- Total canciones
- Popularidad promedio
- Popularidad máxima

Output: `gold/spotify/metricas_artistas.parquet`

Paso 5: Carga a Azure

```
guardar_bronze(datos_bronze)
guardar_silver(datos_silver)
guardar_gold(datos_gold)
```

Sube todo a Azure Data Lake como Parquet (overwrite=True).

Riesgos y cómo los manejo

Qué puede fallar	Qué tan probable	Qué hago
API Deezer caída	Medio	Pipeline sigue solo con CSV
Credenciales Azure malas	Bajo	Falla rápido con error claro
CSV cambió formato	Medio	Validación con JSON Schema
Duplicados en datos	Alto	Deduplicación en Silver

Logs y debugging

Uso logging de Python con 3 niveles: INFO/WARNING/ERROR

Ejemplo de logs:

```
INFO - Descargando spotify_wrapped_2025.csv
INFO - Archivo descargado: 1543 registros
INFO - Capa Bronze creada: 1593 registros
INFO - Capa Silver creada: 1589 registros
INFO - Capa Gold creada: 120 artistas
```

Decisiones técnicas importantes

1. ¿Por qué Deezer y no Spotify API?

Spotify OAuth es complicado. Deezer es pública y gratis.

2. ¿Por qué Parquet?

Más eficiente que CSV:

- Compresión mejor (~10x)
- Lee más rápido
- Guarda tipos de datos

3. ¿Por qué Medallion (Bronze/Silver/Gold)?

Es el estándar en Data Lakes:

- Bronze = raw (puedo reprocesar si algo sale mal)
- Silver = limpio
- Gold = para dashboards

4. Validación con JSON Schema

Detecta cuando el CSV cambia de formato antes de romper todo.

Consecuencias:

- Integración nativa con Synapse
- Particionamiento Hive-style
- Control de acceso granular (RBAC)
- Vendor lock-in con Azure

---

7. Próximos Pasos (Backlog)

1. **Orquestación:** Migrar a Azure Data Factory con triggers diarios
2. **Serving:** Crear tablas externas en Synapse Analytics
3. **Monitoring:** Configurar Azure Monitor con alertas
4. **Calidad de Datos:** Agregar Great Expectations
5. **Reintentos:** Implementar exponential backoff para API
6. **Particionamiento Gold:** Particionar por fecha para datos históricos
7. **CI/CD:** Terraform para IaC de recursos Azure

---
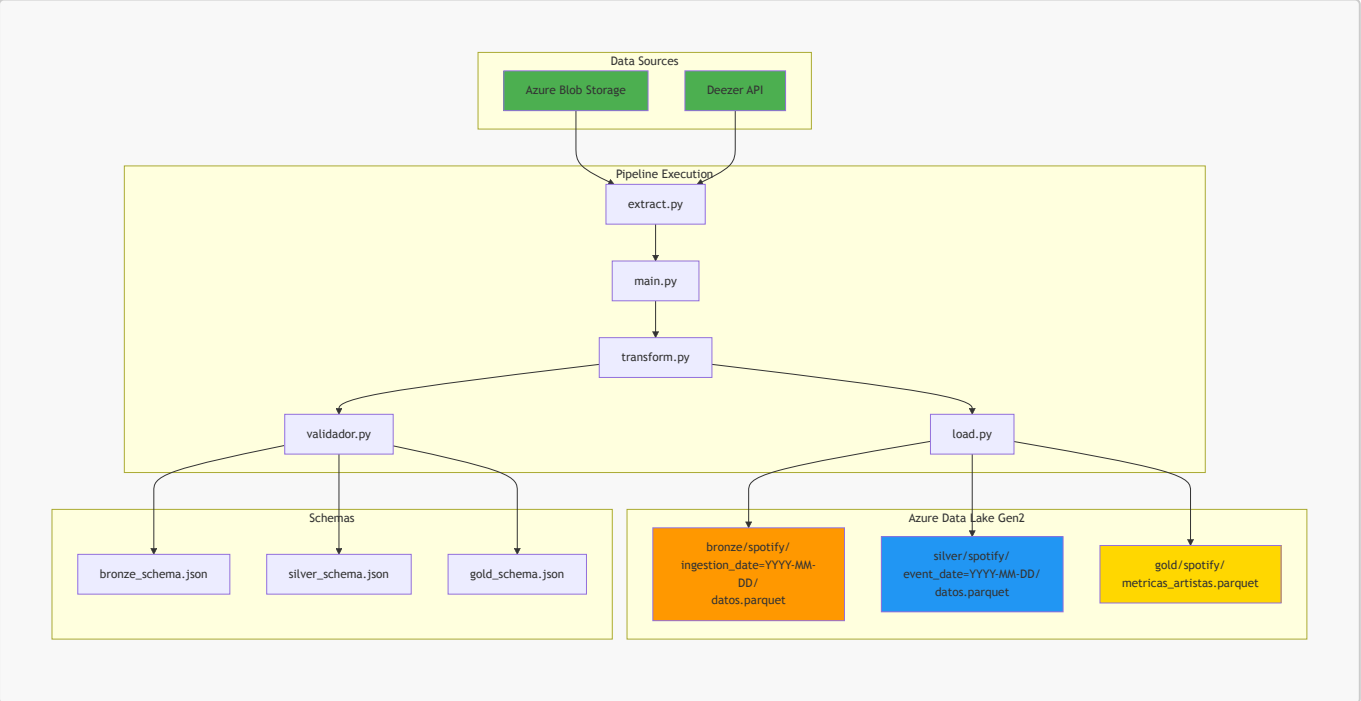
8. Diagrama de Componentes